

Проект по МИИАД

Классификация музыкальных произведений по жанрам

Дживеликян Е.А.
Латышев А.К.
Сизов В.С.

Национальный исследовательский университет
“Московский физико-технический институт”


4 ноября 2020 г.

- 8000 треков по 30 секунд каждый, в формате .mp3
- 8 жанров, 1000 треков для кадного жанра

International
Rock Folk
Electronic
Instrumental
Experimental
Pop
Hip-Hop

Инструменты

Библиотека инструментов
для обработки звука



Признаки

В данной работе были использованы признаки:


- MFCC(Мел-частотные кепстральные коэффициенты)
- Tonnetz
- Средний темп произведения
- Мощность гармонической и перкуSSIONной компоненты

Спектр спектра, но по мел-шкале.

Мел-шкала



Пример MFC




В датасете посчитаны 20 коэффициентов по бинам, на которые разбита песня.

И для каждой последовательности коэффициента рассчитаны статистики: mean, standard deviation, skew, kurtosis, median, minimum and maximum


Tonnetz

Данный признак позволяет оценить наличие гармонии в сигнале, выделить характерные интервалы путём преобразования пространства классов высоты звука.

Пространство высот звука



Пространство интервалов



В данной работе используются различные статистики (те же, что и для MFCC), вычисленные для этого признака по всем фреймам трека.

Темпоральный спектр произведения



Гармоника и перкуссия



ideal harmonic signal



ideal percussive signal



violin



castanets

Вычислены мощности гармонической и перкуSSIONной составляющих треков.

Результаты. Часть 1

Модель	F1	Параметры	Время обучения	ЭВМ
SVC	59.92	kernel='rbf' C=3	20.2 секунды	Intel(R) Xeon(R) CPU @ 2.30GHz Google Colaboratory
Random Forest Classifier	56.23	n_estimators=500 class_weight='balanced'	28 секунд	Intel Core i9 2400 GHz
Gradient Boosting Classifier	57.13	learning_rate=0.05 max_depth=5 n_estimators=200 subsample=0.5	3 минуты 32 секунды	AMD Razer 5 3500U 2100 MHz
Logistic Regression	53.59	C=0.01 solver='lbfgs' multi_class='multinomial'	516 миллисекунд	AMD Razer 5 3500U 2100 MHz
CatBoost	59.34	iterations=800 depth=6 bagging_temperature=0.05 l2_leaf_reg=0	3 минуты 28 секунд	AMD Razer 5 3500U 2100 MHz

Вклад участников

Дживеликян Е.А.

Разбор признаков Tonnetz. Настройка и работа с Gradient Boosting Classifier.

Латышев А.К.


Разбор признаков MFCC и вычисление гармонической и перкуссионной компонент. Настройка и работа с SVC, Logistic Regression, CatBoost

Сизов В.С.

Разбор признаков Temp. Настройка и работа с Настройка и работа с Random Forest Classifier.

VGG эмбеддинги

Для выделения признаков высокого уровня использовалась предобученная на Audioset VGG net.



VGG обучалась определять множество разных меток на 0.960 секундных отрывках на датасете Audioset, полученном из роликов youtube.

LogReg

В качестве baseline использовалась логистическая регрессия, на вход которой подавались эмбединги.

В результате поиска параметра C в диапазоне от 10^{-5} до 1. Была найдена лучшая модель: `solver='newton-cg'`, $C=0.001$.


Accuracy: 53.12

F1 = 52.63

Time: 2 минуты 15 секунд

AMD Razen 5 3500U 2100 MHz

LSTM




Пространство поиска

Сэмплировано случайным образом 200 конфигураций с помощью Ray Tune

размер скрытого слоя	от 2^3 до 2^9 с шагом степени 1
число слоёв	{1, 2, 3, 4, 5}
скорость обучения	$(10^{-4}; 10^{-1})$
размер батча	{16, 32, 64, 128, 256}
дропаут между LSTM	$(0; 25 * 10^{-2})$
дропаут на выходе	$(0; 25 * 10^{-2})$

Использовался ранний останов по validation accuracy и по алгоритму ASHA.

Обучение модели с лучшими параметрами



размер скрытого слоя	64
число слоёв	2
скорость обучения	0.006
размер батча	64
дропаут между LSTM	0.1
дропаут на выходе	0.15

Оптимизатор: Adam

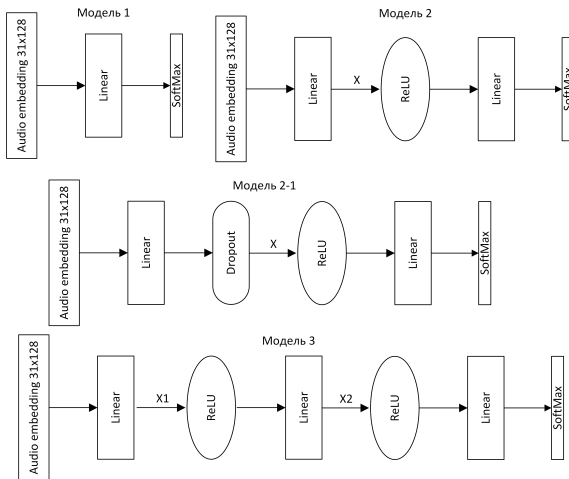
Функция потерь: Cross Entropy на softmax

Результаты на тесте:

Accuracy: 0.55

F1(macro): 0.54

Fully Connected NN




Результаты FCNN

Для трех предложенных моделей использовался оптимизатор SGD ($\text{lr}=0.005$). И лосс функции NLLLoss и CrossEntropyLoss (значимой разницы они не показали).

В моделях 2, 2-1 и 3 подбирались размеры скрытых слоев в диапазоне от 3000 до 50.

Значимых различий для этих моделей и модели 1 не наблюдалось, но в среднем модель 2-1 показала лучший результат (вероятность dropout 0.5).


Лучшая FCNN



красный—валлидация, синий—трейн

Для модели 2-1 был проведен более подробный анализ размера внутреннего слоя. Значения были в диапазоне от 100 до 20 с шагом 10. Было прогнано 3 модели для каждого параметра. В результате лучшим оказалось 30 скрытых нейронов. Количество батчей: 100
 $F1 : 0.4832 \pm 0.0024$
 $AUC : 0.8388 \pm 0.0059$
 $Epoch : 360 \pm 17$

Convolutional NN



Построенная лучшая архитектура состоит из двух сверточных слоёв и одного линейного преобразования

Количество эпох: 60

Размер батча: 300

Лосс функция: CrossEntropyLoss

Результат на трейне:

Loss: 1.147


Accuracy: 0.62

Результат на тесте:

Loss: 1.289

Accuracy: 0.57

F1(macro): 0.5328



Слева—accuracy; справа—loss
(красный—валидация, синий—трейн)

Результаты. Часть 2

Модель	F1	Время обучения	ЭВМ
LogReg (BaseLine)	52.63	2min 15s	AMD Razer 5 3500U 2100 MHz
LSTM	54.01	18s	NVIDIA Tesla T4 Google Colaboratory
Fully Connected NN	48.32	3min 59s	NVIDIA Tesla T4 Google Colaboratory
Convolutional NN	49.01	1min 55s	NVIDIA Tesla T4 Google Colaboratory

Вклад участников

Дживеликян Е.А.

Подготовка эмбедингов. Обучение архитектур с рекуррентными слоями.

Латышев А.К.

Обучение полносвязных глубоких сетей и логистической регрессии.

Сизов В.С.

Обучение свёрточных архитектур.

Все участвовали в оформлении репозитория и презентации.

Основные слайды

① Датасет и инструменты

② Признаки

③ Результаты. Часть 1

④ Результаты. Часть 2

RNN

FCNN

CNN